

FAR-Lab 研究 工作台

证据约束、可证伪、可修订的科学假设生成与研究计划设计系统：从研究问题出发，经真实文献检索、来源核验、主张-证据绑定、多假设对抗排序，到可执行研究计划、确定性实验判决与可复现导出的完整闭环。

1. 研究问题与解决方法

1.1 问题定义

AI Scientist 的核心困难不是“让大模型写出一段像研究计划的话”，而是**证据约束下的可证伪假设生成**：当前 LLM 系统普遍存在证据断层（引用与实际检索内容不对齐）、假设同质化（多个“候选”实为同一机制的改写）、可证伪性空转（提出无法判定对错的陈述）、以及反馈与修正脱节（反馈不改变后续输出）。本作品针对 Direction 1-A（科学假设生成与研究计划设计），构建从研究问题到可执行研究计划的完整证据约束闭环。

1.2 解决方法：证据约束的科研闭环 + 迭代控制

系统的主循环为十二阶段流水线：问题理解 → 文献检索 → 来源验证 → 证据构建 → 假设生成 → 批判与可证伪化 → 排序比较 → 研究计划 → 实验执行 → 反馈 → 修正 → 导出，并在其上叠加三层自适应控制：

- ① **质量门（自适应智能）**：排序后对假设集做确定性弱信号检测（头部得分稀薄 / 排序换位分歧 / 竞争者过少），触发**恰好一轮**有界再生成，将批评注入每个生成策略提示词，并以确定性复述防护阻止第一轮假设的换皮重提。
- ② **运行级 token 预算**：以真实收据（receipts）为唯一支出权威；预算耗尽后各阶段以 budget_exhausted 真实理由跳过、永不阻塞导出，提高上限后恢复运行时精确重开被跳过的阶段。
- ③ **迭代控制器（证伪级联）**：完整通过一遍后，若存在可执行的证伪回路腿（实验→反馈→修正→再冻结→再实验），控制器在轮次上限 / 预算 / 无实质增量三重边界内有界重开——全程确定性决策、全程留痕。

四条不可协商的科学不变量：主张必须由实际检索内容支持（fail-closed 接地）；分数只是决策辅助（永远披露产出者与校准状态，LLM 判分标注 uncalibrated）；修正必须有因果链（反馈→修订→版本对比可解释）；统计判决机械推导（预注册决策规则，绝不由 LLM 判定实验结论）。

2. 架构设计与讲解

2.1 总体架构（五个平面，单一权威）

—— 研究者平面 —— Web 工作台(React18+Vite+SSE) / CLI(far) / TUI(Ink,独立包) / 桌面壳(Tauri v2,加固CSP)
—— 编排平面 —— Orchestrator(租约/checkpoint/恢复) + 迭代控制器 + 质量门 + 预算 + Supervisor(只读观测)
—— 智能平面 —— 12 阶段流水线 + Agent 内核(工具回合/权限引擎/子代理/MCP/Skills) + 受治理跨运行记忆
—— 执行平面 —— 实验运行时(Python sidecar, uv 锁定, sklearn/scipy) + 探索性 CodeAct(双静态门)
—— 真值平面 —— far.db(单一 SQLite 权威: runs/objects/events 只读追加+哈希链/artifacts 内容寻址/receipts)

关键架构裁决：一个 **stage machine**、一个**迭代决策者**、一个**权威存储**。Supervisor 是只读轨迹分析（每个阶段边界恰好一条幂等观测笔记），行动权永远在编排器与人类；记忆是 far.db 内受治理投影（无第二记忆库）；事件表迁移 v7 后由数据库触发器强制只读追加（UPDATE/DELETE 中止）+ SHA256 前向哈希链，用户主导的运行删除走特权路径并留墓碑记录。

2.2 Agent 内核与能力生态

对话与研究回合运行在同一 Agent 内核上：工具注册表 + 顺序权限引擎（未匹配默认 **deny**；ask 无处理者在无头环境降级为 deny；strictest-wins；bypass 免疫拒绝）。常驻对话代理携带只读工具面（列运行/看运行详情/看计划/搜工作区/工作区状态）+ propose_action 审批卡（批准/拒绝/记忆授权）；

自动化引擎（日程 + 运行完成触发）中**记忆授权失效**——自动化回合的提案永远门在人类。外部能力以 MCP 服务器接入（如 IBM Docling 文档理解），**受能力作用域准入约束**：只读证据精炼能力只接入 read 级服务器，非 read 级以 disabled + 策略原因显式拒绝。声明式 hook 规则编译为内核权限（block→不可绕过拒绝，require_approval→精确（工具,参数）审批绑定）。

2.3 安全执行基底（认知安全 T0-T5）

高权限科研 Agent 的硬边界按 OWASP Agentic 威胁模型分层落地：**T1 聚光标记**（外部文献内容走独立数据通道 + 统一不可信内容规则，工具结果按来源标记信任级）；**T2 污损词汇**（域层统一 ContentTaint，外部内容结构性地不可能派生 own 级信任）；**T3 工具边界不可信内容策略**（参数嵌入不可信载荷特征切片的实效工具调用被拒绝，read 级保持自由）；**T5 事件不可变性**（数据库触发器 + 哈希链）。探索性 CodeAct（Agent 撰写分析 Python）经**双静态门**：TS 策略门（网络/子进程/凭据/确证边界/内省逃逸封禁）在任何进程派生之前执行；Python 侧 AST 镜像检查（含 getattr 字符串洗白形式）——2026-08-24 独立对抗审计实证的 dunder 遍历逃逸已在两层同时封禁并有回归测试锁定。探索输出只能是**候选发现**，晋升为确证性结论必须走确定性门。

2.4 模型控制平面

协议无关网关（支持接入全球模型），内置 Zhipu GLM（Anthropic 兼容）与阿里云百炼 DashScope/Qwen 适配器。故障转移链语义经 LiteLLM 源码验证：限速/超时/配额/认证/5xx 在各自重试后转移，400 类与无效输出永不转移；服务路由写入每张收据。使用量账本由收据推导，成本只按用户申报价格计算——未知保持未知，绝不臆造。

配套两条工程保障：**离线确定性开发路线**（wire=offline，无 key、零网络，24 个确定性 purpose 处理器走完整研究流程，全部收据标记 test 模式，实测约 20 秒完成全程并在浏览器中实时观看，用于演示与界面验收而绝不冒充真实模型调用）；**默认路线降级预警**（2026-08-26 真实配额事故驱动：liveReady 只代表“有 key”而非“可调用”，首页健康条交叉核对默认路线近 24 小时失败记录，配额耗尽时以阻断式告警替代“就绪”徽章并给出切换入口）。

3. 代表性测试案例（全部来自真实运行记录）

案例	验证内容	结果	证据
A	真实数据上的假设证伪闭环（2026-08-22, live）	OpenML iris 真实获取 → 预注册统计决策规则的实验 spec → sklearn 训练/评估 → StatReport → FeedbackSignal → 假设被机械判决证伪 → 修正 v0→v1 + VersionDiff 持久化并进入导出包。	evidence/W-EE L/live-traceable-revision.md
B	引用对齐机器验证（live）	两次真实运行合计 19/19 主张与检索内容逐字对齐验证通过（P1 15/15 + P2 4/4）；对齐失败 fail-closed。	evidence/W-EE L
C	反向证据关系可靠性（live）	修复前 contradicts 精确率 30%（上界）→ 标签纪律 + 主题门修复后 0/21 错误、盲评精确率 54.5%。	evidence/W-E V2/relation-precision.md
D	与强基线同裁判对比（MLR-Bench, N=5）	idea 7.00 / proposal 6.20，对比 o4-mini 7.80/7.40、deepseek-r1 7.60/7.00；可行性维度 7.40 超过两个锚点；差距诚实归因，不回避。	评测证据文件

案例	验证内容	结果	证据
E	质量门再生成（回归测试驱动真实阶段）	真实 Orchestrator 驱动真实 generate_hypotheses 阶段，断言第二轮假设确实持久化——此前对抗审计发现再生成标志位死代码（P0），修复并用该真实阶段回归测试锁定。	测试套件
F	故障注入与恢复（offline 20/20 + live）	进程击杀→租约收养 5033-5060ms；相同 (spec, seed, env) 双跑逐字节一致；损坏检查点 fail-closed；跨进程取消→恢复续跑。	evidence/
G	离线全程浏览器实证 + 产品结构重构（2026-08-26）	离线路线在真实浏览器完成“预设→发起→实时观看 12 阶段（约 20 秒）→简报/比较表渲染”闭环；工作区留有存活记录（run_p0xjnnyvdak1sc1v656wgh6tna, completed）；同日六个重构批次（简报 answer-first/假设比较表/证据绑定/研究分组/路线预警/离线旅程修复）全部经真实浏览器验收；旅程本身发现并修复三个真实缺陷。	提交 3df63f5..c38e1f5

案例 H — 现架构与强基线的公平对比（W4R，2026-08-29，全部 live/真实检索）： FAR-Lab（zai glm-4.6 live）6/6 完成：来源核验 72/72=100%、主张-来源绑定 170/170=100%、结构化反证 6/6（104 条反证关系）、计划可执行 6/6；baseline-direct（glm-5.3）引用不受支持率 78.9%、结构化反证 0；baseline-rag（同模型+EuropePMC top-5）引用全部可解析但无主张模型、可执行计划 0/6。协议偏离如实披露且均不利于己方（evidence/W4R/evaluation-report.md）。

案例 I — 判官诚实重校：重发现原报 0.58 经对照实验验证伪（判官宽松伪影）；157 对 gold 零误差重校后复测 0.226，全程如实入账（evidence/W-EV2/rediscovery.md）。系统不通过改指标恢复数字。

工作区累计真值（2026-08-26 读数）： 85+ 个研究运行（52 个完整完成）· 模型调用收据 2951 张 · 累计 931 万 token（三路由真实账本）· 全量确定性测试 2000+ 通过 / 195+ 测试文件 · CI 于真实 GitHub runner 验证绿（run 32983787357），其后提交本地同套门禁全绿（远端重跑受平台 runner 配给故障延迟）。

4. 源代码

开源仓库：github.com/yry1816186-pixel/FAR-Lab（Apache-2.0）；npm install 与 npm run build 后执行 far research start “问题” 一分钟内可复现主流程；npm test 全量确定性验证。

工程不变量：Node 产品运行时依赖仅 zod（其余全部 devDependencies）；实验运行时为 uv 锁定的独立 Python sidecar（sklearn/scipy/numpy 版本锁定 + 锁文件哈希入运行记录）；桌面壳为 Tauri v2。

诚实边界（如实披露）：官方规定的千问/百炼调用路线的真实凭证验证仍缺 DASHSCOPE_API_KEY（结构已就绪、探针脚本已备，B-QWEN-LIVE-ROUTE）；离线确定性路线覆盖管线全程与对话式创建入口（2026-08-27 修复并经浏览器全程验证）；演示视频与交互前端按官方要求随提交包附上。

5. 项目工作流程（研究者视角）

提问（研究形成页：问题输入 + 粘贴/拖放/显式「引文 / 标识符」入口同一条摄入管线 + Zotero 本地库引入 + 离线语音听写；启动前「会发生什么」四步说明常驻，也可经常驻对话打磨问题后一键启动）

→ **研究地图**（单画布 answer-first）：研究问题 → 证据带（参与反证的主张置顶、来源逐条可追） → 排序假设卡 → 当前判断（主要不确定性、未决反证、下一步）；任意对象点击即在右侧 inspector 展开完整卡片 → **研究者直接操作**：主张可排除/固定/连接到假设（支持/反对），排除后假设区分度按剩余证据即时重算（「研究者调整视图」与存储的原始分析两个视图并存披露）；假设可编辑陈述/推进/否决/分叉，编辑与 AI 反馈进入同一条因果修订链（human_expert 反馈 → 修订前后对比 → 版本号递增 → 陈旧性不确定性披露） → **深层工具层**（研究地图「下一步」行进入，按需展开）：评分卡与维度分解（“为什么排第一”的评分理据、GRADE 证据体评级、ACH 判别性证据交叉表——全部确定性计算而非模型判分；跨单元多重检验政策单一权威）、反馈与修订历史、研究计划与确证性实验（声明 MDE，批准时快照当前证伪决策规则，重新校验 fail-closed）、观察迭代轮（时间轴逐轮显示重开阶段与触发原因）、核验与导出 → 导出研究产品（确定性 IMRaD 论文投影：局限性由真实计数合成、BibTeX 只来自存储元数据）+ 一键可复现包（far verify 独立校验）。首页为研究工作区：判断队列（进行中/失败待恢复/反证待审视）+ 研究索引（同一问题的多次运行归并为一个研究条目）。全程执行模式显式标识（LIVE / OFFLINE / RECORDED / SYNTHETIC——研究地图顶栏徽章 + 执行真实性面板）；路线失败（如配额耗尽）时研究进入失败态、首页判断队列按研究者语言显示原因，可从断点恢复，而非起步阶段静默失败或全部重来。

6. 上下文工程设计

通道分离：外部文献文本经 untrustedSourceContent 独立数据通道进入提示词，并附加显式不可信内容规则——这是提示注入防御的 T1 层。

有界信息寻求：首轮证据贫瘠时允许恰好一轮定向补检索（≤2 查询、每查询 ≤3 文档），永不开放循环。

负面条件化：假设生成后续策略可见先前已提主张，防止同质化；跨运行记忆对重复方向施加负面条件。

技能条件注入：内建/用户两级技能按相关性选择注入（≤3 项、≤4000 字符）。

受治理记忆：终态运行确定性投影为情景记忆与实验结论记忆（失败结论**必须**携带失败原因，zod + SQL CHECK 双层强制）；检索为确定性零 LLM（FTS5 + ACT-R 激活排序）；替代为只追加（被替代项保留审计）。

7. 数据或资料来源说明

文献证据全部来自真实检索源：OpenAlex、arXiv、CrossRef、EuropePMC（+全文阶段：arXiv LaTeXML / OpenAlex GROBID TEI）。每个来源保存不可变快照（内容寻址 artifact + 可解析溯源），主张-来源绑定逐字可验证；统计实验数据来自 OpenML 真实数据集（校验和/许可/谱系持久化，种子可复现切分）。评测基准：MLR-Bench；W4R 现架构基线对比（案例 H）；POPPER 式重发现（判官 gold 锁定重校后 mean F1 0.226，判官方差 4/5 任务 swing ≤0.045、gold 精度 0.826 实测；历史 0.58 已证伪留档）；裁判方差研究（worstTaskSwing 0.061 < 0.15 目标）。

8. 结果展示与反馈迭代过程

量化进步（同裁判前后对比）：主张数 +40%（58→81）、反向证据关系 +104%（均值 16→32.67）、token 成本 +84.5% 如实记录；单维不宣称全域优势（18 个质量格中 6 格落后于最佳基线，如实列出）。

反证能力（live 实测）：方向锚定证伪审计 A/B strict 0.625→0.875、反向标签 inverted 9→3；两题合并 strict 0.867（n=30）。

反馈迭代的三条真实路径：① 结构化专家反馈→因果修订（含真实的克隆混杂批评案例）；② 研究者直接编辑→同一因果链；③ 实验判决→FeedbackSignal→修正→再实验（迭代控制器有界级联）。

自我纠错的诚实记录：对抗审计曾抓到再生成死代码 P0（已修+真实阶段回归锁）、探索沙箱 dunder 逃逸 P1（双层封禁+回归测试）、关系标签 30% 错误率（根因修复后 live 复测 0/21）——所有被抓住的缺陷及其修复都是系统能力的一部分，而非需要隐藏的污点。2026-08-26 的离线浏览器旅程延续同一纪律：一次旅程发现并修复离线预设半成品表单、前端 wire 枚举契约漂移（保存成功却报结构不符）、阶段计数口径混淆三个真实缺陷。

已知边界：官方路线凭证待补；多轮真实工作区运行与 live 对比基准等待 live 路由恢复（2026-08-29 后或用户提供新路由）；领域包（天文/生物/化学等）当前为通用科研核心 + 待扩展域语义。

本文档数字全部来自仓库证据文件与真实运行读数；页限按两个官方页面中严格者（20 页）准备。