

XH-202619 · 基于国产开源大模型的 AI Scientist

FAR-Lab

证据约束、可证伪、可修订的科学假设生成与研究计划设计系统——完整技术与使用文档：十二阶段科研流水线、假设锦标赛排序、确定性实验判决、因果修正与版本治理、科学状态投影、可复现导出与独立校验，以及 Web / CLI / 桌面多端工作台的安装、配置与使用指南。

1.1 赛题定位

FAR-Lab 面向赛题方向 1-A（科学假设生成与研究计划设计），构建了一个从研究问题出发、以真实文献证据为约束、以可证伪性为第一等公民、以可执行研究计划与确定性实验判决为出口的完整科研工作台。系统的定位不是文献检索工具，也不是通用对话助手，而是一条闭合的科研主线：

问题 → 真实检索 → 主张-来源逐字绑定 → 多假设生成与可证伪化 → 锦标赛排序比较 → 研究计划 → 确定性实验判决 → 因果修正与版本治理 → 可复现导出与独立校验。

研究者可以在任意环节介入：排除一条证据、编辑一个假设、提交一条专家反馈、批准一次确证性实验——所有介入都进入同一条因果修订链，系统据此重算排序、重开阶段、更新当前科学判断。

1.2 问题定义

大模型驱动的科研系统普遍存在四类结构性缺陷，FAR-Lab 针对每一类给出机制级解法：

缺陷	表现	FAR-Lab 解法
证据断层	引用与实际检索内容不对齐，甚至虚构文献	主张必须绑定来源文档的逐字引文，对齐由机器校验（逐字子串或词级 Jaccard ≥ 0.8 ），未对齐主张永不被计为已验证支持，fail-closed
假设同质化	多个“候选假设”实为同一机制的改写	三策略差异化生成 + 释义聚类去重（Jaccard 0.9 预合并、0.85 再生守卫）+ 文献基础新颖性裁决
可证伪性空转	提出无法判定对错的陈述	可证伪规范九字段强制 + “可判定语义”确定性检查（纯函数，无 LLM），“未来才能检验”类陈述直接失败
反馈与修正脱节	反馈不改变后续输出	反馈信号 → 因果分析 → 逐对象修订（版本号递增、前后归档、RFC 6902 结构化差异）→ 排序重算 → 迭代控制器有界重开实验腿

四条不可协商的科学不变量贯穿全系统：主张必须由实际检索内容支持；分数只是决策辅助（每项评分披露产出者与校准状态，LLM 判分一律标注 `uncalibrated`，证据奠基维度由确定性计算覆盖）；修正必须有因果链（反馈 → 修订 → 版本对比全程可解释）；统计判决机械推导（预注册决策规则与置信区间的纯数学比较，模型不参与实验结论判定）。

1.3 核心能力一览

能力	说明
十二阶段科研流水线	问题理解 → 文献检索 → 来源验证 → 证据构建 → 假设生成 → 批判可证伪化 → 排序 → 计划 → 执行 → 反馈 → 修正 → 导出，全程检查点化、可恢复
四源真实文献检索	OpenAlex、arXiv、CrossRef、EuropePMC；全文深化（arXiv LaTeX HTML / EuropePMC JATS / OpenAlex GROBID TEI）；反证检索配额制
主张-来源逐字绑定	每条证据主张携带 verbatim 引文与定位；GRADE-lite 四级确定性评级；GRIM / 量 程守卫 / E-value 统计取证逐条执行
假设锦标赛排序	12 维评分卡 + 循环赛制成对比较 + Bradley-Terry 聚合 + 种子化 bootstrap 95% 置 信区间
可执行研究计划	行动化步骤（8 类）、proceed/kill 门、四条决策规则、多重检验政策、预注册冻结 （planHash）
确定性实验执行	Python sidecar（uv 锁定）四类实验：OpenML 表格 / Monte-Carlo 模拟 / 已发表效 应 meta 合并 / 远程执行；统计判决机械推导
因果修正与版本治理	9 类反馈源、逐对象版本化修订、RFC 6902 差异、修订谓词（决策规则保留 / 可证 伪性保持 / 范围变化）、不确定性只增不减
科学状态投影	当前判断（领先假设、最强支持与反证、最大未知、序数置信度）+ 下一步研究行 动 + 状态变更链，全部为确定性零 LLM 投影
真值平面	单一 SQLite 权威；追加-只读事件表 + SHA-256 前向哈希链；内容寻址工件；模型 调用回执；执行模式五分类（live / mixed / synthetic / recorded_replay / empty） receipts 驱动
可复现导出与独立校验	IMRaD 论文投影、RO-Crate 1.1 + SWAN JSON-LD 元数据、MANIFEST 逐文件 SHA-256；far verify 11 项确定性校验
模型控制平面	协议无关网关接入全球模型（OpenAI / Anthropic / Gemini 兼容线 + 内置 Zhipu GLM、DashScope/Qwen、DeepSeek 路由）；经验证的故障转移语义；回执驱动的 用量账本；支出上限 fail-closed
常驻对话代理	Agent 内核 + 只读工具面 + propose_action 审批卡 + 自动化引擎（提案永远门在人类）；MCP 外部工具能力作用域准入
跨运行记忆	far.db 内受治理记忆基质：信任分级写入门、FTS5 + ACT-R 激活确定性检索、只追 加替代
多端工作台	Web（研究地图单画布、SSE 实时流、命令面板、离线听写、Zotero 集成、zh/en）、 CLI（far）、TUI（lnk 独立包）、Tauri v2 桌面壳

2.1 五平面架构

研究者平面	Web 工作台（React 18 + Vite + SSE）/ CLI（far）/ TUI（lnk，独立包）/ 桌面壳（Tauri v2，加固 CSP）
编排平面	Orchestrator（租约单写者 / 检查点 / 恢复）+ 迭代控制器 + 质量门 + 运行预算 + Supervisor（只读观测）
智能平面	十二阶段流水线 + Agent 内核（工具回合 / 权限引擎 / 子代理 / MCP / 技能）+ 受治理跨运行记忆
执行平面	实验运行时（Python sidecar，uv 锁定，sklearn / scipy / numpy）+ 耐久调度器 + 探索性 CodeAct（双静态门）
真值平面	far.db（单一 SQLite 权威：runs / objects / 追加-只读哈希链 events / 回执）+ 内容寻址 artifacts

三条关键架构裁决：

1. 一个 **stage machine**、一个**迭代决策者**、一个**权威存储**。阶段推进、检查点与恢复由编排器独占；迭代重开决策由迭代控制器以确定性规则独占；所有研究对象的唯一事实源是 far.db，前端与导出物都是投影。
2. **Supervisor 只观测不行动**。轨迹分析在每个阶段边界恰好产生一条幂等观测笔记并持久化，行动权始终在编排器与人类手中。
3. **记忆不是第二数据库**。跨运行记忆是 far.db 内受 zod schema 与 SQL CHECK 双层治理的投影，检索为确定性零 LLM 计算，不存在独立的记忆存储权威。

2.2 技术栈与工程约束

层	技术
产品运行时	Node.js ≥ 24 , TypeScript 严格模式 (noUncheckedIndexedAccess 开启)；生产运行时依赖仅 zod (schema 校验)，其余全部为 devDependencies
存储	SQLite (node:sqlite, WAL 模式)，9 版迁移链；实验调度器使用独立 SQLite (WAL 隔离)
HTTP	原生 node:http + 手写路由，零 Web 框架；SSE 为原生 text/event-stream
前端	React 18 + Vite 6 + Tailwind CSS v4, hash 路由，SSE / 轮询双通道
实验运行时	Python ≥ 3.11 , uv 锁定 (sklearn / scipy / numpy 版本锁定，锁文件哈希入运行记录)，stdio JSON Lines 协议
桌面壳	Tauri v2 (Rust 后端，加固 CSP)
测试	Vitest 3, forks 池，202 个测试文件，全量确定性离线运行

2.3 单一权威与数据流

一次运行的完整数据流：[ResearchQuestion](#) (scope 阶段精炼) → 语料快照 (检索 + 去重 + 融合 + 反证配额后 ≤ 12 篇) → [source_document](#) (含不可变快照工件) → [claim](#) (逐字绑定 + GRADE 确定性) → [evidence_relation](#) (11 种关系类型, CiTO 本体对齐) → [hypothesis](#) (版本化) → [scorecard](#) + [tournament](#) → [plan](#) (预注册冻结) → [experiment_spec](#) / [experiment_run](#) / [stat_report](#) → [feedback](#) → [revision](#) + [version_diff](#) → [bundle](#) (导出)。每一环节写入均同时产生事件与 (如涉及外部调用) 回执；对象、事件、回执三者共同构成可独立审计的真相面。

3.1 阶段总览

#	阶段	核心职责	LLM 参与方式
1	scope	问题精炼：领域、现象、纳入/排除范围、目标类型	单次结构化调用（temp 0.2）
2	retrieve	四源检索、去重融合、反证配额、引用图扩展、窗口重排	查询规划 + 列表重排；融合与配额为确定性
3	verify_sources	标识符解析与错配风险评级	无（确定性路由）
4	build_evidence	主张提取、逐字对齐门控、统计取证、GRADE 评级、交叉关系	主张提取与关系裁决；对齐/取证/评级为确定性
5	generate_hypotheses	三策略生成、去重聚类、多样性补充、新颖性裁决	三次结构化调用（temp 0.7）+ 裁决调用
6	critique_falsify	可证伪规范、反证链接、对抗性链接审计	批判调用 + 二次独立审计调用
7	rank	12 维评分卡、成对锦标赛、证据奠基计算	维度自评（标注 uncalibrated）+ 成对裁决；奠基与聚合为确定性
8	plan	行动化研究计划、可执行性门、预注册冻结	计划起草；执行性门与冻结为确定性
9	execute	实验腿执行（表格 / meta 合并）	实验规格起草；执行与判决为确定性
10	feedback	反馈接收记账、预测结算	无 LLM（纯记账）
11	revise	因果分析、逐对象修订、版本差异	因果分析调用；谓词校验为确定性
12	export	报告 / 论文 / 可复现包	零 LLM 确定性投影

3.2 问题理解与范围界定（scope）

输入研究问题文本（可附研究者提供的种子材料：PDF、DOI、BibTeX/RIS、Zotero 条目、语音听写文本），输出结构化范围：领域、现象列表、纳入范围、排除范围、目标类型（解释性 / 预测性 / 干预性 / 方法学 / 探索性）与约束。原始问题文本永远保留。Web 端支持"草稿 → 范围提案 → 研究者编辑确认 → 启动"的预发布流程：scope-proposal 端点仅执行 scope 阶段后暂停，研究者审阅并修改范围后才推进。

3.3 文献检索与语料构建（retrieve）

检索阶段是系统中工程密度最高的部分，关键机制：

- **查询计划强制反证**：查询计划schema强制包含发现型（2条）、支持型（1–2条）与**反证型（≥2条）**查询；正则门控要求至少一条查询包含反证词汇；确定性锚定修复（纯函数）在查询与主题脱锚时重建锚点。
- **多源路由**：反证查询路由至 OpenAlex / EuropePMC / CrossRef 三源（arXiv 反证查询因实测 82.3% 零结果率确定性重定向至 CrossRef）。
- **三层去重**：主键去重（DOI > arXiv id > 首个标识符）+ 模糊标题键（CJK 感知归一化）+ MinHash 近重复合并（阈值 0.5）。
- **RRF 融合**：倒数排序融合（k=60），并列时按出现次数、反证来源优先、首见顺序确定性破序。
- **反证配额**：最终语料为反证文献保留最低席位（4 席），置换规则将低排名非反证文献挤出。
- **引用图扩展**：后向引用 + 前向引用 + 二跳追逐（有界）；撤稿文献永不竞争席位。

- **窗口化列表重排**：候选池 > 48 篇时，自底向上滑动窗口（窗口 24、步长 12）做 RankGPT 式列表判定重排。
- **自适应补检索（gap-seek）**：当已验证主张数低于 $\max(3, \text{可用文档}/2)$ 时，允许恰好一轮定向补检索（ ≤ 2 条查询，源轮转），永不开放循环。
- **语料上限**：最终语料 ≤ 12 篇（MAX_DOCUMENTS），快照不可变持久化。

3.4 来源验证（verify_sources）

标识符确定性路由解析：DOI $\rightarrow$ Crossref、arXiv id $\rightarrow$ arXiv API、PMID $\rightarrow$ EuropePMC。解析结果三态（resolved / not_found / error）；标题门控失败时计算**错配风险评级**（姓氏重叠、年份差、期刊兼容性），防止“引用存在但指向错文”。

3.5 证据构建与主张-来源绑定（build_evidence）

- **逐字对齐门控**：每条提取主张必须携带来源文档的 verbatim 引文；对齐判定为逐字子串匹配或词级 Jaccard ≥ 0.8 。未对齐主张标记 resolved_unaligned，永不计为已验证支持。
- **统计取证**：对每条含数值主张的引文执行 GRIM 检查（均值 $\times$ 样本量整数一致性，句子级 mean-n 配对）、量程守卫与 E-value（VanderWeele–Ding 闭式解）计算，全部为确定性正则提取与算术。
- **GRADE-lite 确定性评级**：合并绑定验证状态、定量性、来源时效、矛盾信号、取证失败与撤稿状态，四级（high / moderate / low / very_low）阶梯降级；撤稿直接 floor 至 very_low。
- **全文深化**：最多 3 篇文档做全文获取（16k 字符摘录上限，结构化理解文档持久化）。
- **主张间交叉关系**：确定性主题预过滤（包含度 ≥ 0.25 或共享词 ≥ 4 ）后 LLM 裁决，产出 11 种关系类型（supports / contradicts / weakens / qualifies / depends_on / derived_from / replicates / fails_to_replicate / alternative_explanation / methodological_limitation / unknown），与 CiTO 本体对齐；证据强度由确定性映射推导（绑定等级 $\times$ 定量性），文献主张封顶 moderate。

3.6 假设生成（generate_hypotheses）

三条互补生成策略各一次结构化调用（temp 0.7 保多样性）：**证据条件化**（从已验证主张组合）、**矛盾驱动**（从文献间冲突关系）、**机制穷举**（从领域机制空间）。反同质化机制：后续策略可见全部已提候选；释义聚类 + Jaccard ≥ 0.9 预合并；再生成轮的换皮守卫（Jaccard ≥ 0.85 拒绝）。聚类代表数 < 3 时触发多样性补充算子（integrate / reduce / make-feasible / transplant）。每条假设经**文献基础新颖性裁决**（查询扩展 $\rightarrow$ OpenAlex 邻居检索 $\rightarrow$ 剖面重排 $\rightarrow$ novel / incremental / already_done / unclear 四分类）。跨运行记忆对重复方向施加负面条件。中文界面陈述由批量 temp 0 翻译生成。每策略步进检查点（输入指纹覆盖提示词与纪律常量）。

3.7 批判与可证伪化（critique_falsify）

可证伪规范强制九个必填字段（各 > 10 字符）并通过“可判定语义”确定性检查（正则模式集合，纯函数无 LLM）：含“未来才能检验”类不可判定表述直接失败。批判阶段为假设建立显式**反证链接**（主张 假设，关系标签显式声明，缺省 weakens），随后由**独立对抗性链接审计**（不同框架的第二次审查）对每条提议链接做 confirm / relabel / drop；链接通过主题门控（扩展至陈述 + 机制 + 预测三字段），产出 ACH 风格的判别性证据分析。

3.8 排序与比较 (rank)

- **12 维评分卡**：科学合理性、证据奠基、反证暴露、新颖性、可证伪性、可测试性、数据可得性、方法可靠性、期望信息增益、资源成本、风险、不确定性。每维披露分值、定性说明、理据、证据主张引用、产出者与校准状态 (`deterministic` / `uncalibrated_llm_judgment` / `human_expert`)。其中**证据奠基维度**由**确定性**计算覆盖：9 级对数似然比带映射基值 + QBAF 分数组合，LLM 自评不参与该维。
- **成对锦标赛**：循环赛制编排（每候选 5 轮、总对局 ≤ 24 ），顺序交换的双重裁决（分歧记平局），Bradley-Terry ILSR 聚合（200 次迭代， $\delta < 1e-10$ 收敛），mulberry32 种子化 bootstrap（1000 轮，固定种子）给出每假设胜率 95% 置信区间。
- **最终排序**：锦标赛分 $\rightarrow$ 组合分 $\rightarrow$ 证据奠基 $\rightarrow$ id 确定性破序。证据体评级与 ACH 判别性分析以加性项并入。加权体系：证据奠基 0.20、可证伪性 0.15、反证暴露 0.15、科学合理性 0.15、方法可靠性 0.15、可测试性 0.10、新颖性 0.10（成本与风险在方向已知时各 0.05）。

3.9 研究计划设计与预注册 (plan)

从排名前 ≤ 2 的假设代表起草研究计划。计划 schema 为行动化结构：**步骤**（8 类：文献 / 数据分析 / 工具运行 / 模拟 / 实验 / 人工评审 / 阴性对照 / 其他，每步含方法、失败条件、`proceedIf` / `killIf` 门）、**指标**（ ≥ 2 项，主/次角色、方向声明）、**四条决策规则**（成功、弱化、证伪、停止判据）、**多重检验政策**（单一主指标 / α 支出 / E-value 累积，多假设时必填）、目标试验协议（因果声明七要素）、结构化预测（假设 $\times$ 可观察量 $\times$ 条件 $\times$ 期望关系，冲突矩阵检查）。**确定性可执行性门**：目标非空、假设引用可解析、步骤依赖可解析、指标与规则齐备，任一不满足则计划不通过。步骤 id 由服务端规范化重映射（服务器拥有 canonical id）。通过 **Wave-S 结构化预注册** 审计后冻结（`planHash` + `frozenAt`，任何漂移前落定）；计划发射时的预测与排序同时登记入自校准账本。

3.10 实验执行 (execute)

运行生命周期内执行**恰好一条**计划起草的实验：OpenML 表格数据集路径或已发表效应统计合并（`statistical_meta`）路径。目标列漂移触发确定性单次重试；实验执行失败按“带理由跳过”处理而非运行失败；预算耗尽向上传播。实验产物（`spec` / `run` / `result_set` / `stat_report`）全部持久化。

3.11 反馈与因果修正 (feedback / revise)

feedback 阶段为纯记账（无 LLM、幂等）：接收 9 类反馈源（人类专家、新文献、新数据集、工具结果、模拟、实验、评审意见、验证失败、复现失败），并结算自校准账本（实验判决按正当评分规则对比无知基线结算预测，最差优先聚合：`falsifies` $>$ `weakens` $>$ `supports` $>$ `inconclusive`）。revise 阶段对每条未消费信号执行因果分析（受影响对象 + 因果链 + 期望质量变化），随后逐对象修订：假设版本号递增并归档前版，计划重新过门并重新冻结。**存在性预言机**过滤无效对象引用。三个确定性修订谓词披露于对象：决策规则逐字保留度、可证伪性保持度、范围变化率。版本差异为 RFC 6902 结构化 patch ops。**不确定性只增不减**为系统级约束。因果分析未命名可修订对象时，信号诚实保持未消费状态。

3.12 导出 (export)

零 LLM 确定性投影：10 节 Markdown 研究报告、IMRaD 论文（含由真实计数合成的局限性章节、只来自存储元数据的 BibTeX）、确定性图表（假设胜率 SVG、语料深度 SVG）、结果表（CSV + Markdown 双份）。可复现包见第九章。

4.1 质量门（自适应再生成）

排序完成后对假设集做确定性弱信号检测，任一触发即判定弱集：排序假设数 < 2、头部组合分 < 0.45、排序换位分歧率 > 0.4。弱集触发**恰好一轮**有界再生成（总轮次上限 2）：每假设底部维度作为批评注入各生成策略提示词，确定性复述防护（Jaccard 0.85）阻止第一轮假设换皮重提。再生成由真实编排器驱动真实生成阶段并有回归测试锁定。

4.2 运行级 token 预算

以模型调用回执为**唯一支出权威**（从回执 usage 重导出，恢复安全）。预算耗尽后各阶段以 `budget_exhausted` 真实理由跳过，导出阶段**永不被**预算门控；提高上限后恢复运行时精确重开被跳过的阶段。预算上限经 `FARLAB_RUN_TOKEN_BUDGET` 配置，80% 软预警。

4.3 迭代控制器（证伪级联）

完整通过一遍后，迭代控制器评估是否存在可执行的证伪回路腿：**未消费反馈** → 重开 [feedback, revise, export]；**可执行计划未执行 / 计划已修订未再实验** → 重开 [execute, feedback, revise, export]。停止边界三重：轮次上限（默认 3，可配 1–10）、预算耗尽、无实质增量（快照物质计数 + SHA-256 指纹对比）。无 actionable 工作时诚实停止并给出解锁提示。实验腿状态机四态（无计划 / 未执行 / 计划已修订 / 当前）与执行阶段共享所有权语义。

4.4 编排器：租约、检查点与恢复

租约单写者模型（TTL 240s，可配）：每次异步边界后重检租约，防收养窗口竞态。阶段内步骤检查点按 family 组织，输入指纹（覆盖提示词与纪律常量）使陈旧缓存存在提示词升级后自动失效。恢复模式三类：反馈驱动恢复（已完成 + 新信号）、证据债恢复（已完成 + 未验证来源）、预算恢复。进程意外终止后由租约收养接管；损坏检查点 fail-closed，不产生假状态。

五、科学状态投影：研究判断的单一入口

科学状态投影层是确定性零 LLM 的纯函数投影，从运行自身持久化对象（评分卡、反证关系、不确定性字段、修订历史）合成研究者可直接消费的判断三件套，经 `GET /api/v1/runs/:id/science` 暴露，并在研究地图中呈现。

5.1 当前科学状态（ScientificState）

- **状态分类**四态：forming（形成中） / insufficient（证据不足） / evidence_backed（证据支持） / template（模板态——离线路线的模板内容占据科学表面时的诚实降级，**永不**为模板内容合成"领先解释"）。
- **领先假设**：为什么领先（取自头部四个评分维度的理据），而非仅引用排名第一。
- **最强支持与最强反证**：按证据强度排序选取并引用。
- **竞争视图**：前三个假设各自差异所在（differsBy）。
- **判别性观察**：来自可证伪规范的判别量。
- **最大未知**：确定性优先级消解（未决反证 > 假设不确定性 > 检索无反证 > 模板态 > 无活跃假设）。
- **置信度**：序数定性等级 + 依据声明（非概率数字）。
- **证据形态**：主张总数、已验证数、反证数等真实计数。

5.2 下一步研究行动 (NextAction)

10 类行动（换 live 路线重跑 / 宣告证据不足 / 执行计划内实验 / 消费反馈入修订 / 恢复证据债 / 反证检索 / 判别性分析 / 补判别数据 / 扩展文献 / 研究者审视反证），按优先级排序返回前 4 项。每项含：目标、知识缺口、理据、**会改变什么** (wouldChange)、期望判别力、可行性与成本等级、是否需要研究者决策、可执行性提示——仅当真实产品操作存在时标记为可执行（如恢复运行、换路线重跑），否则为引导性建议。

5.3 状态变更链 (StateDelta)

从修订历史投影“什么变了、为什么、下一步是什么”：版本对 (v0 → v1)、触发者（反馈源 + 摘录）、变更内容、受影响假设与主张、排序影响（削弱 / 加强 / 重构 / 不明）、解释、质量变化、剩余不确定性；有版本差异工件时直接消费 RFC 6902 patch ops。新者在前的变更日志。

5.4 服务端点与前端呈现

GET /api/v1/runs/:id/science 返回 { state, nextActions, deltas, experimentLeg, unconsumedFeedbackCount }。研究地图的状态带（当前判断）、行动带（下一步行动，含一键恢复 / 重跑入口）与变更带（最近变更）直接渲染该投影；运行期间每 4 秒刷新。

6.1 执行架构与耐久调度

实验执行采用 Node 主进程 + Python sidecar 架构：sidecar 经 uv run --frozen 启动（依赖版本锁定，锁文件哈希入运行记录），线程环境固定（OMP / OPENBLAS / MKL = 1, PYTHONHASHSEED = 0）保证浮点确定性；通信为 stdio JSON Lines 协议（{id, op, payload} → {id, ok, result?, error?}）。操作集：env_info（环境指纹）、train_eval（训练 + 逐行正确性）、dataset_audit（数据质量审计：泄漏 / 重复 / 标签问题）、abs_stats / paired_stats（统计检验：CI / p 值 / bootstrap）、simulate（Monte-Carlo 逐 replicate 数组）。

耐久调度器运行于独立 SQLite：作业表含优先级、状态机（queued / running / completed / failed / canceled / dead）、**围栏令牌**（每次认领 / 心跳 / 完成必须携带当前令牌，僵尸进程无法覆盖）、5 秒心跳、尝试计数耗尽（默认 5，可配 1-20）进入死信队列；far.db 侧经事务性 outbox 模式与调度器幂等对接。CLI 提供 run / enqueue / worker / status / logs / cancel 全套操作。

6.2 四类实验

类型	说明
表格机器学习	OpenML 真实数据集（ARFF 获取 → CSV 解析，校验和 / 许可 / 谱系持久化）或本地 CSV（SHA-256 校验）；种子可复现切分；确定性数据集身份（同源同 id）
Monte-Carlo 模拟	模拟规格多配置逐 replicate 执行，进入同一统计判决链
统计合并（statistical_meta）	纯 TS 实现：LLM 仅提议已发表效应估计，准入门校验后做 fixed / random(DL) / LOO / Egger 合并，判决机械推导
远程执行	SSH 网关将同一实验规格转发远程执行，终端统计链一致

6.3 机械统计判决

判决是点估计 / 置信区间与预注册阈值的纯数学比较：区间完全落于阈值一侧 → supported / refuted，跨阈值 → inconclusive；成对比较支持 paired-t 与 paired bootstrap CI；多重检验按政策执行（单一主指标仅主指标校正 / alpha 支出均分）；隐含功效由 $MDE / \alpha / n_{Test}$ 计算。**LLM 不产生实验结论**。数据集获取后以实际行数重新验证 n_{Test} 下界与 MDE 可达性（获取后门控）。

6.4 探索性分析与双静态门

Agent 可撰写探索性分析 Python (CodeAct)，经**双静态门**在任何进程派生之前执行：TypeScript 侧策略门（网络 / 子进程 / 凭据 / 确证边界 / 内省逃逸封禁）+ Python 侧 AST 镜像检查（含 getattr 字符串洗白与 dunder 遍历形式）。探索输出只能是**候选发现**，晋升为确证性结论必须走确定性门。确证性实验另设研究者审批绑定：批准时快照当前证伪决策规则，重新校验 fail-closed。

7.1 多协议接入

协议无关网关支持接入全球模型：内置路由 Zhipu GLM（Anthropic 兼容线，默认）、阿里云百炼 DashScope / Qwen（OpenAI 兼容线，赛题指定路线）、DeepSeek、universal（openai / anthropic / gemini 三线，经 FARLAB_UNIVERSAL_* 环境路由）；自定义端点可经 custom: 配置或编程注册接入任意兼容服务。Web 设置中心提供模型配置 CRUD、连接测试（maxTokens=16 真实调用）、模型发现（/models 端点枚举）、20 个提供商一键模板（OpenAI、Anthropic、Google Gemini、xAI、OpenRouter、Groq、Mistral、Together、Perplexity、Cohere、Fireworks、Cerebras、DeepSeek、Moonshot、智谱、百炼、Ollama、vLLM、LM Studio 与离线开发路由）。

7.2 故障转移链

语义经对照 LiteLLM 源码验证：限速 / 超时 / 配额 / 认证 / 5xx 在各自重试后转移下一跳；400 类与无效输出**永不转移**（请求本身有问题，换路由无意义）。冷却 60 秒按配置索引。**实际服务路由写入每张回执——多跳链路中研究者可追溯每次调用真正由谁服务。**

7.3 用量账本与支出上限

用量账本完全由回执推导（聚合幂等），按 (provider, modelId) 分组统计调用数与 token。成本规则：**无内置价格表**，成本只来自用户申报定价；未声明价格的路由由成本显示 unknown，绝不臆造为零。工作区支出上限 (USD) 在提供方边界 fail-closed：达到上限后调用被拒绝（不可重试类错误），未定价调用诚实排除在限额计算外。

7.4 竞赛路由门与离线路线

competition-route 端点提供竞赛模式开关：开启后强制经百炼调用 Qwen 系模型。系统另含**离线确定性路线**（wire = offline）：无 key、零网络，29 个确定性 purpose 处理器（25 个精确键 + 4 个前缀键，schema 权威为各阶段 zod schema）走完整研究流程，全部回执标记 test 模式，实测约 20–30 秒完成全程并可在浏览器实时观看——用于演示与界面验收，回执与界面双重显式标注，绝不冒充真实模型调用。首页健康条交叉核对默认路线近 24 小时失败记录：配额耗尽时以阻断式告警替代“就绪”徽章并给出切换入口。

8.1 内核循环与权限引擎

对话与研究回合运行在同一 Agent 内核：结构化工具使用循环（JSON-schema 约束的动作空间）、双层上下文压缩（微压缩 → 完整交接压缩 → 降级）、步/总超时与停止条件、finish 结果 schema 校验重问、超大工具结果外溢至工件存储。**外泄扫描**在每次工具调用前检查凭据与金丝雀标记。权限引擎为顺序优先级（deny > ask > allow，未匹配默认 **deny**；ask 在无头环境降级为 deny；strictest-wins；bypass 模式对危险操作免疫拒绝不可绕过）；ask 决定缓存 5 分钟（键为工具 + 参数深度排序哈希）。子代理并行扇出（并发 ≤ 3，深度 ≤ 1，工具集可裁剪）。

8.2 常驻对话代理与审批卡

常驻对话代理携带只读工具面：列运行、看运行详情、看计划、搜工作区、工作区状态。行动经 [propose_action](#) 审批卡提出（launch_research / cancel_run / create_tool_integration / create_automation / cancel_automation 五类），研究者批准 / 拒绝并可勾选“记住此决定”（记住的授权种类可随时整体撤销）。对话支持：多格式附件摄入（PDF / BibTeX / RIS / TXT / MD / DOCX / XLSX / PPTX / HTML / JSON / EPUB / SVG / CSV，自动解析提取文本）、工具调用轨迹展开、失败重试、思考档位（low / medium / high）、斜杠命令、语音听写；对话打磨出的问题一键结晶为研究运行。对话可全屏或停靠于研究地图旁。

8.3 自动化引擎

自动化以日程间隔或运行完成为触发，由引擎代研究者在对话中发起回合。**记忆授权在自动化回合中结构性失效**——自动化提案永远门在人类审批，不会因历史“记住”决定而自动执行。

8.4 MCP 工具集成与技能

外部 MCP 服务器（stdio 与 HTTP 两种传输）经工具集成面（TIS）接入：远程工具名清洗、连通性测试（tools/list 往返）、插件目录导入（经 reviewed 诚实门）。**能力作用域准入**：只读证据精炼能力只接入 read 级服务器，非 read 级以 disabled + 策略原因显式拒绝；服务端声明的 hints 仅用于展示，不影响权限判定。声明式 hook 规则编译为内核权限（block → 不可绕过拒绝，require_approval → 精确（工具，参数）审批绑定）。技能系统为 Markdown + frontmatter 清单（无 YAML 依赖），内建 / 项目 / 用户三层，按任务相关性条件注入（≤ 3 项、≤ 4000 字符），不匹配零开销。

8.5 跨运行记忆基质

记忆与 far.db 同库（无第二记忆库）。四类记忆（情景 / 语义 / 实验结论 / 画像），生命周期 active → superseded → archived（只追加替代，被替代项保留审计）。**信任分级写入门**：[own_verified](#) 要求运行与回执真实存在否则降级；[external_literature](#) 要求可解析来源引用否则降级为不可信；zod 与 SQL CHECK 双层强制。检索为确定性零 LLM：FTS5 短语 + trigram（CJK / 长查询）+ LIKE 退化，ACT-R 激活排序 $\log(1+accessCount) / (1+ageDays/14)^{0.5}$ 。运行到达终态时确定性固化：实验结论记忆**必须**携带失败原因（schema 强制），参与证据关系的已验证主张固化为语义记忆。

8.6 上下文工程设计

- **通道分离**：外部文献文本经 [untrustedSourceContent](#) 独立数据通道进入提示词，附显式不可信内容规则（提示注入防御 T1 层）。
- **有界信息寻求**：证据贫瘠时恰好一轮定向补检索（≤ 2 查询、每查询 ≤ 3 文档），永不开放循环。
- **负面条件化**：假设生成后续策略可见已提主张；跨运行记忆对重复方向施加负面条件。
- **技能条件注入**：按相关性选择注入，限额限定。

- 受治理记忆：检索与写入均确定性，LLM 不参与记忆治理决策。

9.1 存储结构

far.db 单库权威，9 版迁移链。核心表：[runs](#)（运行行 + 租约字段）、[events](#)（追加-只读审计事件）、[objects](#)（33 种对象类型的泛型存储，主键 (kind, id)）、[step_outputs](#) / [step_fingerprints](#)（阶段内检查点与输入指纹）、[lineage_edges](#)（谱系边）、[event_tags](#)（标签索引，支持 kind / stage 查询平面）、[memory_items](#) / [memory_edges](#) / [memory_fts](#)（记忆基质）、[outbox](#)（跨库事务性发件箱）、[corpus_items](#)（研究者文献库）、[deleted_runs](#)（删除墓碑）。

9.2 追加-只读事件与哈希链

事件表由数据库触发器强制只读追加（UPDATE / DELETE 中止），每条事件携带 [prev_hash = SHA256\(prev_prev_hash || prev_payload || current_payload\)](#) 前向哈希链；[verifyEventChain](#) 逐条重算可检测任何历史篡改；写入时钟回退自动插入跳变笔记。研究者主导的运行删除走特权路径（临时降触发器 → 删除 → 重建）并留墓碑记录。

9.3 内容寻址工件

文献快照、报告、论文、图表等工件按 [artifacts/<2位前缀>/<sha256>](#) 布局存储；同哈希不同内容为硬错误；写入先落临时文件再原子 rename。对象引用工件哈希，构成不可变快照链。

9.4 模型调用回执与执行真值

每次模型调用 / 来源检索 / 工具执行持久化一张回执：类别、**执行模式**（live / test / replay）、时延、token 用量、提供方、模型 id、服务路由、错误链。执行真值投影完全由回执驱动（零 LLM）：五分类 live / mixed / synthetic / recorded_replay / empty，经 [GET /api/v1/runs/:id/truth](#) 暴露；Web 界面顶栏徽章（LIVE / OFFLINE / RECORDED / SYNTHETIC）与执行真实性面板同源。回执同时是用量账本与预算的唯一数据源。

9.5 研究产品导出

一键可复现包（ZIP）内容：[report.md](#)（研究报告）、[paper.md](#)（IMRaD 论文）、[references.bib](#)（BibTeX，引用完整性硬校验）、[figures/](#)（假设胜率图、语料深度图，SVG）、[tables/](#)（结果 / 语料 / 主张绑定表，CSV + Markdown 双份）、[bundle.json](#)（bundle 对象规范化 JSON）、[ro-crate-metadata.json](#)（RO-Crate 1.1 研究对象描述）、SWAN JSON-LD 溯源描述、[MANIFEST.json](#)（全部文件 SHA-256 清单）、[README.md](#)（人类入口 + 校验命令）。声明证据等级 $\in \{\text{inspect, replay, recompute}\}$ ；依赖锁哈希与代码修订号入包。语料增长或新修订产生导出债时支持重导出。

9.6 独立校验（far verify）

[far verify <bundle-id>](#)（或 [GET /api/v1/verify/:bundleId](#)）对包执行 **11 项确定性检查**：bundle 可读且 schema 有效；来源工件哈希全部可解析且内容匹配；最终工件哈希匹配；回执可读且模型元数据一致；路由与执行模式方向一致并披露执行真值；语料快照引用可解析；问题引用可解析；校验说明非空；局限性至少一条（非确定性诚实门）；依赖锁哈希匹配（漂移报 degraded）；声明证据等级合法；全部主张携带污点标签。判定三态 verified / degraded（仅依赖锁漂移） / failed。

10.1 认知安全分层（对照 OWASP Agentic 威胁模型）

- **T1 聚光标记**：外部文献内容走独立数据通道 + 统一不可信内容规则；工具结果按来源标记信任级。
- **T2 污损词汇**：域层统一 ContentTaint，外部内容结构性不可能派生 own 级信任；记忆写入与导出校验双重执行（bundle 校验第 11 项即污点标签检查）。
- **T3 工具边界不可信内容策略**：参数嵌入不可信载荷特征切片的实效工具调用被拒绝（防注入内容借工具外逃），read 级工具保持自由。
- **T5 事件不可变性**：数据库触发器 + 哈希链（第九章）。
- **外泄防御**：每次工具调用前的凭据 + 金丝雀出站扫描。

10.2 探索沙箱

CodeAct 双静态门（第六章）：TS 策略门在任何进程派生之前执行，Python AST 镜像检查覆盖字符串洗白与 dunder 遍历逃逸形式，两层均有回归测试锁定。沙箱命名空间受限，网络 / 子进程 / 凭据 / 内省封禁。

10.3 密钥与数据安全

密钥只经环境变量 / .env（真实环境变量优先，可整体关闭注水）进入，永不入库、入日志、入提示词；.env.example 提供完整注解模板。服务默认绑定 127.0.0.1（本地优先单工作区模型）；桌面壳 CSP 加固；定期密钥扫描与路径卫生门禁脚本随仓库发布。权限体系 least-privilege：代理默认只读工具面，行动类操作一律审批卡。

十一、Web 工作台

Web 工作台（React 18 + Vite 6 + Tailwind v4，hash 路由）以**研究地图单画布**为中心组织，配合首页研究工作区与深度工具视图，覆盖研究全生命周期。

11.1 信息架构

#/ 首页研究工作区；#lab/new 研究形成；#study/<runId> 研究地图（主视图）；#run/<runId>/<tab> 深度工具六视图；#conv/<id> 对话全屏；对话亦可停靠于研究地图旁（?conv=）。hash 路由支持前进后退、直输 URL 与分享链接。

11.2 首页：研究工作区

判断队列聚合四类需要研究者注意的条目：正在运行（实时阶段）、需关注（部分完成 / 失败待恢复）、草稿（待范围审阅或启动）、含反证研究的已完成运行。**研究索引**将同一问题的多次运行归并为一个研究条目。首页同时呈现对话列表与路线健康条（默认路线降级预警，见第七章）。

11.3 研究形成

问题输入 + 种子材料托盘（文件 / 链接 / 拖放 / 粘贴 / Zotero 选取 / 离线语音听写，同一条摄入管线）+ 模型路由选择器 + 目标类型选择；支持两条启动路径：直接启动，或"草稿 → 范围提案 → 编辑确认 → 启动"的预审流程。URL ?q= 参数预填问题文本（模板重跑场景）。启动前"会发生什么"四步说明常驻。

11.4 研究地图（主视图）

纵向推理地图，自上而下：**问题区块**（问题 + 范围标签）→ **状态带**（当前科学状态：领先解释与领先理由、最强支持、最强反证、竞争视图、判别性观察、最大未知、序数置信度与依据、证伪条件；模板态诚实降级显示）→ **行动带**（下一步研究行动：目标 / 缺口 / 理由 / 会改变什么 / 判别力 / 可行性 / 成本，可执行行动一键恢复或重跑）→ **变更带**（最近状态变更链）→ **证据带**（主张列表，参与反证的主张置顶，来源逐条可追，排除项原位弱化而非隐藏）→ **假设带**（按排名的活跃假设卡 + 判别性观察 + 研究者调整后的 ACH 视图）。运行中显示实时叙事带（当前阶段、进度、最新事件、二次确认取消）；中断运行显示恢复带；无活跃假设时进入证据不足裁决路径。点击任意主张或假设在右侧 **inspector** 展开完整卡片。

11.5 研究者直接操作

- **主张操作**：置顶 / 取消置顶、重分类（核心证据 / 反证 / 背景 / 方法学关切）、自由注释、排除（必填理由）、恢复；排除后假设区分度按剩余证据即时重算，“研究者调整视图”与存储的原始分析两个视图并存披露。
- **主张-假设连接**：选择假设与方向（supports / counters）建立显式关系。
- **假设操作**：提升、拒绝、分叉、编辑陈述——编辑与 AI 反馈进入**同一条因果修订链**（human_expert 反馈 → 修订前后对比 → 版本号递增 → 陈旧性不确定性披露）。

11.6 深度工具视图与可视化

六视图：研究概览（阶段时间线 + Supervisor 轨迹 + 评估器投影）、证据（主张列表 + GRADE 评级 + 证据关系图 + 证据平衡视图）、假设（锦标赛交叉表 + 评分卡表 + 雷达对比 + 维度热力图 + ACH 网络表）、计划（计划 DAG + 预算 + 实验记录 + 确证性审批）、修订（因果修订链 + 版本差异 + 森林图）、核验（bundle / 报告 / 论文 / PROV-O 谱系导出）。原始事件流以审计级详情默认折叠呈现。

11.7 命令面板与全局搜索

Ctrl+K 命令面板：导航命令、最近 10 条运行快速跳转、用户自定义命令、设置与主题语言切换；2 字符起触发**跨运行全局搜索**（FTS5 bm25 排名，覆盖问题 / 假设 / 主张 / 对话，命中片段高亮直达对象）。

11.8 实时事件流

SSE（EventSource）连接运行事件流：**Last-Event-ID** / 游标参数断线恢复，1 秒推送节拍，无事件保活 ping，10 分钟硬超时，反缓冲头。前端连接状态芯片显式呈现五态（open / live / retrying / unsupported / gave-up），放弃流后自动降级轮询；事件按序号游标幂等合并，SSE 与轮询路径统一。

11.9 离线语音听写

完全离线的语音输入：Web Worker 内 Whisper ONNX 推理，16 kHz 单声道重采样，最长 120 秒，权限请求超时保护，错误分类（麦克风拒绝 / 不可用 / 不支持 / 模型缺失 / 加载失败 / 转写失败），Esc / 右键取消，录制 / 转写状态机有独立视觉反馈。

11.10 Zotero 集成

本地 Zotero 桥接（Zotero 运行时读取文献库与注释）：文献列表（标题 / 年份 / 作者 / DOI / 标签 / 集合）、Canvas 力导向**关系图谱**（共享关键词 / 共同作者 / Zotero related 三种边，拖拽缩放悬停详情）、BibTeX / RIS 文件与粘贴导入、搜索过滤；选中条目连同注释作为种子材料进入研究形成。

11.11 文献筛选工作台

ASReview 模式主动学习筛选：单卡片流（标题 / 年份 / 作者 / 摘要），I / E 键盘二选一判定，模型概率阶段与随机阶段显式标注，实时进度与 include / exclude 计数，WSS@95 风格停止估计（覆盖率 + 可停判据 + 依据说明），停止后总结并生成反馈信号。

11.12 设置、国际化与可访问性

设置中心六区：模型路由（配置 CRUD / 测试 / 用量 / 支出上限 / 模板 / 发现）、工具集成、自动化、外观、数据安全、关于。中英双语（模板插值、语言切换同步 `<html lang>` 与本地存储、locale 时间格式）；三档主题（auto / light / dark）跨标签页广播同步；多运行感知条（活跃运行快速切换）；反馈抽屉从任意对象发起结构化反馈。可访问性目标 WCAG 2.2 AA：核心旅程全键盘可操作、IME 安全输入、减弱动效尊重、颜色不作唯一编码。

12.1 far 命令参考

命令	功能
far research start "问题" --domain D --goal G	创建并执行完整研究运行（目标类型：explanatory / predictive / interventional / methodological / exploratory）
far research status <id> [--watch]	运行状态快照 / 2 秒刷新的实时监视
far research inspect <id> --evidence/--hypotheses/--plan/--sources	检视指定输出对象
far research resume <id>	从最后检查点恢复失败 / 部分运行
far research feedback <id> --source S --content C --target-kind K --target-id T	记录结构化反馈（驱动因果修订）
far research export <id> --format report/bundle --out DIR	导出报告 / 可复现包
far research cancel <id>	取消运行
far new	交互式向导（TTY，中文提示）
far runs [--json]	运行列表
far probe [zai --live]	路线健康检查（配置检查零 token；--live 真实调用约 1 token）
far verify <bundle-id>	可复现包 11 项独立校验
far experiment run/enqueue/worker/status/logs/cancel	实验执行全套（规格执行 / 优先级入队 / 工作者模式 / 监控 / 日志 / 协作取消）
far agent refine <id> --turns N --top-k K	已完成运行的证据缺口精炼
far data info	数据足迹
far completion bash/zsh	Shell 补全

12.2 典型 workflow

```
git clone https://github.com/yry1816186-pixel/FAR-Lab.git && cd FAR-Lab
npm install && npm run build
export ZAI_API_KEY=your_key      # 或 DASHSCOPE_API_KEY 等任一路线

far research start "What mechanisms drive horizontal transfer of antibiotic resistance genes in biofilms?" \
  --domain microbiology --goal exploratory
far research status <run-id> --watch # 实时观看 12 阶段推进
far research inspect <run-id> --hypotheses --plan
far research feedback <run-id> --source human_expert \
  --content "H-003 的机制与近年的 CRISPR-Cas 研究矛盾" --target-kind hypothesis --target-id H-003
far research export <run-id> --format bundle --out ./output
far verify <bundle-id>          # 独立环境校验
```

12.3 编程接口

```
import { createApp } from 'far-lab/app/composition.js';
import { ResearchQuestion, ScientificGoalType } from 'far-lab/domain/index.js';

const app = await createApp({ providerName: process.env.FARLAB_MODEL_PROVIDER ?? 'zai' });
const question = ResearchQuestion.parse({
  text: "How does tumor heterogeneity affect immunotherapy response?",
  domain: 'oncology', goal: ScientificGoalType.Explanatory,
});
const run = app.store.createRun(question);
const result = await app.orchestrator.execute(run.id);
const hypotheses = app.store.listObjects('hypothesis', run.id);
```

12.4 TUI 与桌面壳

可选交互式 TUI ([packages/tui](#), Ink, 独立包, 永不成为 Node 核心依赖) ; Tauri v2 桌面壳提供系统托盘、深链、全局热键与加固 CSP。

13.1 环境要求

Node.js ≥ 24 、npm ≥ 10 ；实验执行需 Python ≥ 3.11 + uv (仅 sidecar) ；SQLite 经 [node:sqlite](#) 内置，无外部数据库服务。

13.2 安装与启动

```
npm install      # 安装依赖 (生产运行时依赖仅 zod)
npm run build    # TypeScript 编译至 dist/
npm test         # 全量确定性测试 (202 个测试文件)
npm run serve    # 启动 API + Web 工作台 (默认 http://localhost:3196)
```

CLI 在启动时注水 .env (真实环境变量优先, FAR_DOTENV=off 关闭)。

13.3 环境变量

变量	说明
ZAI_API_KEY / DASHSCOPE_API_KEY / DEEPSEEK_API_KEY	模型路线密钥（至少配一条；ZHIPU_API_KEY 为 zai 兼容旧名）
FARLAB_UNIVERSAL_*	universal 路由三线（openai / anthropic / gemini）接入任意兼容端点
FARLAB_MODEL_PROVIDER	默认提供方：zai / dashscope / deepseek / universal
FARLAB_DATA_DIR	数据根目录（数据库 + 工件，默认 .far-run）
PORT / HOST	HTTP 服务端口（serve 默认 3196，未设 PORT 时服务监听 8787） / 绑定地址（默认 127.0.0.1）
FARLAB_LEASE_TTL_MS	运行租约 TTL（默认 240000）
FARLAB_STAGE_CONCURRENCY	每阶段最大并发子任务（默认 3）
FARLAB_RUN_TOKEN_BUDGET	运行级 token 预算上限（默认不限）
FARLAB_MAX_ITERATION_ROUNDS	迭代轮次上限（默认 3，范围 1–10）
FARLAB_GIT_COMMIT	溯源用代码修订号（默认自动检测）
OPENALEX_API_KEY / OPENALEX_MAILTO / CROSSREF_MAILTO	文献源礼貌池与速率配置

13.4 模型路线选择

值	路线	协议
zai	智谱 GLM（默认，GLM-4-plus）	Anthropic 兼容
dashscope	阿里云百炼 / Qwen（赛题路线）	OpenAI 兼容
deepseek	DeepSeek	OpenAI 兼容
universal	任意 OpenAI / Anthropic / Gemini 兼容端点	三线自适应
custom:	自定义端点（Web 设置中心或 src/providers/custom.ts 注册）	可编程

十四、HTTP API 参考 (/api/v1, 共 70+ 端点)

分组	端点 (节选)
运行生命周期	GET/POST /runs、GET/DELETE /runs/:id、POST /runs/:id/cancel resume fork reexport、PATCH /runs/:id/question、POST /runs/:id/scope-proposal
事件	GET /runs/:id/events?afterSeq=、GET /runs/:id/events/stream (SSE)、GET /runs/:id/state-at/:seq (时间旅行重建)
科学状态	GET /runs/:id/science (状态 + 行动 + 变更 + 实验腿)、GET /runs/:id/truth (执行真值)
研究对象	GET /runs/:id/question sources evidence hypotheses plan revisions receipts experiments calibration evaluations lineage supervision corpus
假设操作	POST /runs/:id/hypotheses/:hypId/promote reject fork edit connect
主张操作	POST /runs/:id/claims/:claimId/annotate pin unpin exclude reinstate reclassify
实验 / 筛选 / 搜索	POST /runs/:id/experiments/:explId/approve、GET/POST /runs/:id/screening*、POST /runs/:id/counter-search、GET /search?q= (跨运行全局搜索)、GET /memory (记忆检索)
导出与校验	GET /runs/:id/report paper package bundles prov、GET /verify/:bundleId
对话 / 自动化 / 代理	GET/POST /conversations*、消息与重试、POST /conversations/:id/launch、提案审批、思考档位、GET/PATCH/DELETE /automations*、GET/DELETE /agent-policy*
工具集成	GET/POST /tools*、连通性测试、插件导入
模型配置	GET/POST/PUT/DELETE /model-configs*、活跃路由、内置路由、测试、用量、支出上限、模板、模型发现
系统与摄入	GET /health meta、GET/PUT /competition-route、POST /ingest (多格式摄入)、GET /zotero/library annotations

15.1 端到端证伪闭环 (真实数据)

完整闭环实测: OpenML 真实数据集 (iris, id 61) 获取 → 预注册统计决策规则的实验规格 → sklearn 训练 / 评估 → 统计报告 → 反馈信号 → **假设被机械判决证伪** → 修正 v0 → v1 + 版本差异持久化并进入导出包。判决由置信区间与预注册阈值的数学比较得出, 模型未参与结论。

15.2 主张-来源对齐

两次完整 live 运行合计 **19/19** 条主张通过逐字对齐机器校验 (15/15 + 4/4) ; 对齐失败即 fail-closed, 不存在"自称已验证"的未对齐主张。

15.3 反证关系质量

反证关系抽取经盲评: 主题门控与标签纪律约束下错误率 **0/21**, 盲评精确率 54.5%。

15.4 外部基准对比 (MLR-Bench, N=5, 同裁判)

Overall 均值 (同裁判、同任务, n=5/格)

维度	FAR-Lab (live 运行)	o4-mini-2025-04-16 (发表件)	deepseek-r1 (发表件)
idea Overall	7.00	7.80	7.60
proposal Overall	6.20	7.40	7.00

六维细分中的结构性优势与差距（逐格如实）： idea **Feasibility（可行性）7.40**，高于两个锚点（锚点区间 **6.60–7.00**）——赛题所依赖的计划 / 可证伪性机器被判为比锚点方案更可执行；差距集中在 Novelty（5.60 对 7.00–7.40，证据 fail-closed 约束下的诚实新颖性评级与呈现方式所致）与 Consistency（7.20 对 8.60–8.80，任务对齐的映射层问题）。两侧以相同评分细则、相同提示词、相同温度评判，格式不对称性（锚点为精修 markdown、本系统为结构化对象渲染）已披露、未做跨格式校正。

15.5 重发现基准（POPPER 式）

5 个科学史重发现任务：mean F1 0.58，其中 2/5 完美重发现；评判步方差 ± 0.5 task-F1 如实披露。

15.6 评判稳定性

裁判方差研究：worstTaskSwing 0.061，低于 0.15 的设计目标——同裁判对比结论不因任务排序抖动而翻转。

15.7 管线量化改进（同裁判前后对比）

主张数 +40%（58 $\rightarrow$ 81）、反向证据关系 +104%（均值 16 $\rightarrow$ 32.67）；token 成本 +84.5% 同步如实记录（反证与主张密度的代价）。

15.8 可靠性与故障恢复

故障注入实测：进程击杀后租约收养 **5033–5060 ms** 完成；相同 (规格, 种子, 环境) 双跑结果**逐字节一致**；损坏检查点 fail-closed 不产生假状态；跨进程取消 $\rightarrow$ cancelled $\rightarrow$ 恢复续跑；实验执行失败按带理由跳过、运行不失败；预算耗尽优雅跳过且导出永不被门控。执行模式与真实性的机器分类（live / mixed / synthetic / recorded_replay / empty）与界面标注一致。

15.9 工作区规模与测试体系

真实工作区累计：**85+ 个研究运行（52 个完整完成）、2951 张模型调用回执、931 万 token**（多路线真实账本）。确定性测试体系：**202 个测试文件、2000+ 测试用例**全量离线通过（Vitest forks 池），覆盖域 schema、管线各阶段、提供方、文献源、Agent 内核、记忆、谱系、实验、API 端点、CLI 命令与回归守卫；CI 在真实 GitHub runner 验证通过。离线确定性路线可在浏览器中约 20–30 秒完整演示十二阶段全程，界面与回执双重标注离线模式。

十六、数据与资料来源

- **文献证据：**全部来自真实检索源 OpenAlex、arXiv、CrossRef、EuropePMC；全文获取走 arXiv LaTeXML HTML、EuropePMC JATS XML、OpenAlex GROBID TEI 三条确定性路由。每个来源保存不可变快照（内容寻址工件 + 可解析溯源标识），主张-来源绑定逐字可验证。
- **统计实验数据：**OpenML 真实数据集（校验和 / 许可 / 谱系持久化，种子可复现切分）与研究本地 CSV（SHA-256 校验）。
- **评测基准：**MLR-Bench（同裁判对比）、POPPER 式重发现任务集、裁判方差研究协议。

- **溯源本体**：对象谱系与导出采用 PROV-O (JSON-LD)、RO-Crate 1.1 与 SWAN 描述；证据关系与 CiTO v2.8 对齐。
- **开源与许可**：仓库 github.com/yry1816186-pixel/FAR-Lab, Apache License 2.0（第三方署名见 NOTICE）；`npm install && npm run build` 后一条命令可复现主流程，`npm test` 全量确定性验证。